

6. 凸问题和 KKT 条件

朱天宇

1 凸问题建模和性质

凸优化问题一般要解决

$$\begin{aligned} \min \quad & f_0(\mathbf{x}) \\ \text{s.t.} \quad & f_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, m \\ & a_j^\top \mathbf{x} = 0, \quad j = 1, \dots, p \end{aligned} \tag{1}$$

这其中，

1. $\mathbf{x} \in \mathbb{R}^n$, 是优化变量
2. $f_0: \mathbb{R}^n \rightarrow \mathbb{R}$, 被称为目标函数, 或者是 **cost function**
3. $f_i(\mathbf{x}) \leq 0$, 不等式约束
4. $f_i: \mathbb{R}^n \rightarrow \mathbb{R}$, 被称为不等式约束函数
5. $a_j^\top \mathbf{x} = 0$, 线性等式约束

凸问题的条件 在1中, 如果 f_0, f_1, \dots, f_m 都是凸函数, 那么这就是一个凸优化问题。需要注意的是, 等式约束必须是线性约束。

可行域、可行点 可行域就是所有约束的可行域的交集; 如果可行域 \mathcal{D} 非空, 则称1为可行的 (**feasible**)。在实际问题之前, 需要先判定可行域是否非空。

最优值 v^* 最优解 \mathbf{x}^* 在可行域中, 使得 $f_0(\mathbf{x})$ 的下确界所对应的值。如果问题是不可行的, 则 $v^* = \infty$ 。最优值是一个下确界, 不能保证最优解存在。 $f_0(\mathbf{x}^*) = v^*$ 。局部最优的定义和之前的也是相似的。凸优化问题的任意局部最优解也是全局最优解。

1.1 一阶最优性条件

如果目标 f_0 是可微的, 那么点 \mathbf{x} 是最优解, **当且仅当** 对于任意定义域的点 \mathbf{y} , 满足

$$\nabla f_0(\mathbf{x})^\top (\mathbf{y} - \mathbf{x}) \geq 0$$

。

对于无约束的情况, 这个条件退化为

$$\nabla f_0(\mathbf{x}) = 0$$

对于**仅包括等式约束**的情况, 问题可以写成:

$$\begin{aligned} \min \quad & f_0(\mathbf{x}) \\ \text{s.t.} \quad & \mathbf{Ax} = \mathbf{b} \end{aligned}$$

此时最优性条件可以写成

$$\nabla f_0(\mathbf{x})^\top \mathbf{u} \geq 0, \forall \mathbf{u} \in \mathcal{N}(\mathbf{A})$$

这里 $\mathcal{N}(\mathbf{A})$ 表示矩阵的零空间, 也就是使得 $\mathbf{Ax} = 0$ 的解空间。仅包含等式约束的凸优化问题的解与等式约束的零空间正交。

相对于一般的优化问题, 一阶最优性条件仅仅是充分条件, 而对于凸优化, 一阶最优性条件是充要条件。¹

¹<https://www.zhihu.com/question/24641575/answer/507237591>

2 具体的凸优化问题

2.1 线性规划 (LP)

$$\begin{aligned} \min \quad & \mathbf{q}^\top \mathbf{x} + r \\ \text{s.t.} \quad & \mathbf{G}\mathbf{x} \leq \mathbf{h} \\ & \mathbf{A}\mathbf{x} = \mathbf{b} \end{aligned} \tag{2}$$

线性规划问题的目标函数和约束都是线性的。通常在目标函数的 r 可以忽略。其求解的基本思想给其他凸优化问题很多启发。

2.2 二次规划 (QP)

$$\begin{aligned} \min \quad & \frac{1}{2} \mathbf{x}^\top \mathbf{P}\mathbf{x} + \mathbf{q}^\top \mathbf{x} + r \\ \text{s.t.} \quad & \mathbf{G}\mathbf{x} \leq \mathbf{h} \\ & \mathbf{A}\mathbf{x} = \mathbf{b} \end{aligned} \tag{3}$$

2.3 二次约束的二次规划 (QCQP)

$$\begin{aligned} \min \quad & \frac{1}{2} \mathbf{x}^\top \mathbf{P}_0 \mathbf{x} + \mathbf{q}_0^\top \mathbf{x} + r_0 \\ \text{s.t.} \quad & \frac{1}{2} \mathbf{x}^\top \mathbf{P}_i \mathbf{x} + \mathbf{q}_i^\top \mathbf{x} + r_i \leq 0, i = 1, \dots, m \\ & \mathbf{A}\mathbf{x} = \mathbf{b} \end{aligned} \tag{4}$$

2.4 二阶锥规划 (SOCP)

$$\begin{aligned} \min \quad & \mathbf{f}^\top \mathbf{x} \\ \text{s.t.} \quad & \|\mathbf{L}_i \mathbf{x} + \mathbf{g}_i\|_2 \leq \mathbf{c}_i^\top \mathbf{x} + \mathbf{d}_i, i = 1, \dots, m \\ & \mathbf{A}\mathbf{x} = \mathbf{b} \end{aligned} \tag{5}$$

“二阶锥”体现在其约束上。二阶锥规划的目标函数是线性的。

在 $\mathbf{c}_i = 0$ 的时候，SOCP 是 QCQP 的一个特殊情形。但实际上，SOCP 有更好的模型化能力，也就是说更加“广义”，任意的 QCQP 都可以被归纳为一种 SOCP 的特殊情况。

2.5 QCQP 转为 SOCP

引入辅助变量 y , 使得 $\frac{1}{2} \mathbf{x}^\top \mathbf{P}_0 \mathbf{x} + \mathbf{q}_0^\top \mathbf{x} + r_0 \leq y$, 那么 QCQP 问题4就可以写成

$$\begin{aligned} \min_{\mathbf{x}, y} \quad & y \\ \text{s.t.} \quad & \frac{1}{2} \mathbf{x}^\top \mathbf{P}_i \mathbf{x} + \mathbf{q}_i^\top \mathbf{x} + r_i \leq 0, i = 1, \dots, m \\ & \frac{1}{2} \mathbf{x}^\top \mathbf{P}_0 \mathbf{x} + \mathbf{q}_0^\top \mathbf{x} - y + r_0 \leq 0 \\ & \mathbf{A}\mathbf{x} = \mathbf{b} \end{aligned} \tag{6}$$

问题6仍然是一个 QCQP 问题。但是6的目标函数已经是一个线性约束了 (SOCP 的目标函数是线性函数), 接下来需要将约束变成 SOCP 的形式就可以了。

对于一个二次约束 $\frac{1}{2}\mathbf{x}^\top \mathbf{P}\mathbf{x} + \mathbf{q}^\top \mathbf{x} + \mathbf{r} \leq 0$, 由于 $\mathbf{P} \in S_+^n$, 即是半正定的, 故而可以找到一个根 \mathbf{L} , 使得 $\mathbf{L}\mathbf{L} = \mathbf{P}$ 。


$$\tilde{\mathbf{L}} = \begin{bmatrix} \mathbf{L} \\ \mathbf{q}^\top \end{bmatrix}, \quad \tilde{\mathbf{g}} = \begin{bmatrix} 0 \\ \vdots \\ 0 \\ \mathbf{r} + \frac{1}{2} \end{bmatrix} \in \mathbb{R}^{n+1}$$

这里, $\tilde{\mathbf{L}}$ 是一个 $(n+1) \times n$ 的矩阵, $\tilde{\mathbf{g}}$ 是一个 $n+1$ 维。

从而有

$$\|\tilde{\mathbf{L}}\mathbf{x} + \tilde{\mathbf{g}}\|_2 \leq -(\mathbf{q}^\top \mathbf{x} + \mathbf{r} - \frac{1}{2})$$

从而转为了 SOCP 的形式。



3 凸问题的特殊性

3.1 拉格朗日函数 Lagrangian

回顾本章开头, 凸优化问题的通式1

$$\begin{aligned} \min \quad & f_0(\mathbf{x}) \\ \text{s.t.} \quad & f_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, m \\ & h_j(\mathbf{x}) = 0, \quad j = 1, \dots, p \end{aligned} \quad (7)$$

记录符号 $\mathcal{D} = \cap_{i=0}^m \text{dom} f_i \cap \cap_{j=1}^p \text{dom} h_j$ 为问题的定义域。也就是约束的定义域的交集。

定义 **拉格朗日函数**：

$$L(\mathbf{x}, \lambda, \nu) = f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i f_i(\mathbf{x}) + \sum_{j=1}^p \nu_j h_j(\mathbf{x})$$

函数 L 的定义域为 $\text{dom} L = \mathcal{D} \times \mathbb{R}^m \times \mathbb{R}^p$ 。如果 \mathbf{x} 被固定住, 那么 L 关于 λ, ν 是线性的。 λ, ν 被称为拉格朗日乘子, 或者叫做对偶变量。

3.2 拉格朗日对偶函数

定义拉格朗日对偶函数 $g: \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$:

$$g(\lambda, \nu) = \inf_{\mathbf{x} \in \mathcal{D}} L(\mathbf{x}, \lambda, \nu) = \inf_{\mathbf{x} \in \mathcal{D}} (f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i f_i(\mathbf{x}) + \sum_{j=1}^p \nu_j h_j(\mathbf{x})) \quad (8)$$

值得注意的是, 对偶函数 g 是在 \mathbf{x} 的整个定义域 \mathcal{D} 中, 对 L 取下确界获得的。 \mathcal{D} 是由约束函数的定义域的交集构成, 并不要求一定要满足约束。也就是说, 可能存在 $\mathbf{x}_0 \in \mathcal{D}$ 使得某个 $f_i(\mathbf{x}) > 0$ 。在取完下确界 \inf 之后, \mathbf{x} 就被消掉了。

由于拉格朗日对偶函数是关于 λ, ν 线性的, 故而其一定是凸的, 无论原始问题7是不是凸的。

最优值的下界 记 v^* 是原始问题7的最优值 (不是最优解, 是最优值), 那么对于任意的 $\lambda \geq 0, \nu$, 必然有

$$g(\lambda, \nu) \leq v^*$$

这样就为原问题的最优值确定了一个下界。尽管这是一个粗糙的下界, 这个下界的取值可能是 $-\infty$ 。为了获得一个最好的下界, 就需要解优化问题:

$$\begin{aligned} \max \quad & g(\lambda, \nu) \\ \text{s.t.} \quad & \lambda \geq 0 \end{aligned} \quad (9)$$

这个问题被称为 **Lagrange dual problem**, 相应的, 原问题7被称为原问题 (primal problem)。

整个逻辑思路为: 原问题7 \Rightarrow 拉格朗日函数8 \Rightarrow 对偶问题9

原问题和对偶问题 对偶问题9总是一个凸问题, 无论原问题是否是凸的; 使用 λ^*, ν^* 表示对偶问题的最优解, 对于对偶问题的最大值 g^* , 显然有

$$g^* \leq v^*$$

这条性质被称为 **弱对偶性**。对偶问题的最大值小于原问题的最小值。对偶问题和原问题之间存在一个 **gap**。在如果 **gap** 等于 0, 则对偶问题的最优值就等于原问题的最优值。

Slater's condition 满足 $g^* = v^*$, 这被称为强对偶性。强对偶性是一个比较高的条件, 对于一个凸的原问题, 还需要对其附加额外条件, 才能使其具备强对偶性。

Slater's condition²是一个比较容易验证的强对偶性条件。如果 $\exists \mathbf{x} \in \text{relint} \mathcal{D}$, 使得 $f_i(\mathbf{x}) < 0, i = 1, \dots, m$, 那么就满足 **Slater's** 条件。这里 $\text{relint} \mathcal{D} = \{\mathbf{x} \in \mathcal{D} | B(\mathbf{x}, r) \cap \text{aff} \mathcal{D} \subseteq \mathcal{D}, \text{ for some } r > 0\}$, 也就是说存在一个点 \mathbf{x} , 在其周围的球 $B(\mathbf{x}, r)$ 与 $\text{aff} \mathcal{D}$ 相交的范围, 是 \mathcal{D} 的子集, 且这个点满足所有不等式约束。

互补-充实条件 对于不等式约束 $\lambda_i^*, f_i(\mathbf{x}^*)$, 满足互补充实条件, 意味着

$$\lambda_i^* f_i(\mathbf{x}^*) = 0, i = 1, \dots, m$$

也就是说, 当 $\lambda > 0$ 的时候, 要有 $f(x) = 0$; 如果 $f(x) < 0$, 就要求 $\lambda = 0$ 这里需要更加详细的说明。

4 KKT 条件

假设函数 $f_0, f_1, \dots, f_m, h_1, \dots, h_p$ 都是可微分的。且 \mathbf{x}^* 是原问题的最优解, (λ^*, ν^*) 是对偶问题的最优解, 且两个问题的 **gap** 为 0。

由于 \mathbf{x} 可以最小化 $L(\mathbf{x}, \lambda^*, \nu^*)$, 就有

$$\nabla f_0(\mathbf{x}^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(\mathbf{x}^*) + \sum_{j=1}^p \nu_j^* \nabla h_j(\mathbf{x}^*) = 0$$

这条加上上述提及的各种约束, 最终得到 **KKT 系统**:

$$\begin{cases} f_i(\mathbf{x}^*) \leq 0, & i = 1 \dots m \\ h_j(\mathbf{x}^*) = 0, & j = 1 \dots p \\ \lambda_i^* \geq 0, & i = 1 \dots m \\ \lambda_i^* f_i(\mathbf{x}^*) = 0, & i = 1 \dots m \\ \nabla f_0(\mathbf{x}^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(\mathbf{x}^*) + \sum_{j=1}^p \nu_j^* \nabla h_j(\mathbf{x}^*) = 0 \end{cases} \quad (10)$$

这五个条件中, 前两个是原本携带的等式不等式约束; 三四五互补充实条件; 五是 **KT** 条件。

后续的算法围绕着 **KKT 系统** 出发。

²<https://zhuanlan.zhihu.com/p/58064316>